

Análise de Eficiência Energética do Algoritmo de Renderização Neural Guiada por 3D DLSS 4.5

Bernardo F. de Souza¹, Lucas B. de Souza¹, Pedro D. Pilchowski¹, Sérgio G. Filho¹

¹Instituto de Ciência e Tecnologia – Universidade Federal de São Paulo (UNIFESP)
Avenida Cesare Mansueto Giulio Lattes, 1201 – São José dos Campos – SP – Brasil

{bernardo.friske, lbsouza, pedro.ernesto, sergio.garcia}@unifesp.br

Abstract. *This article describes the methods and results obtained from evaluating the performance of the DLSS 4.5 algorithm on the RTX 5060 GPU. During development, the algorithm was implemented via a publicly available port for the game Cyberpunk 2077. Execution involved measuring key variables to analyze the efficiency and cost of using DLSS; results showed that the fluidity gains provided by 4× Frame Generation boosted energy efficiency to 1.66 FPS/Watt with a marginal 4.8% increase in GPU power consumption. However, aggressive upscaling profiles shifted the bottleneck and raised CPU power consumption by up to 69.54%. By leveraging an architecture based on multiple Large Language Model (LLM) agents for data analysis, the researchers were able to draw precise conclusions regarding the impact of the variables involved. Ultimately, it was found that less extreme performance settings offered a superior practical balance between frame rate and hardware thermal-electrical stress.*

Resumo. *Este artigo descreve os métodos e resultados obtidos para a avaliação de desempenho do algoritmo D.L.S.S. 5 aplicado à G.P.U. RTX5060. Durante o desenvolvimento, o algoritmo foi aplicado através de uma portabilidade disponível publicamente no jogo Cyberpunk 2077. Durante a execução, foram medidos os valores de diferentes variáveis de interesse para a análise da eficiência e custo do uso do D.L.S.S., onde constatou-se que o ganho de fluidez proporcionado pelo Frame Generation 4× elevou a eficiência energética para 1,66 FPS/Watt com um incremento marginal de apenas 4,8% no consumo da GPU, ao passo que perfis agressivos de upscaling deslocaram o gargalo e elevaram o consumo da CPU em até 69,54%. Com o auxílio de uma arquitetura baseada em múltiplos agente de grandes modelos de linguagem (LLM's), os valores obtidos pelos testes permitiram conclusões precisas acerca dos efeitos das variáveis do teste. Obteve-se que configurações menos extremas de desempenho demonstraram melhor compromisso prático entre a taxa de atualização e o desgaste termelétrico do hardware.*

1. Introdução

Ao longo da história, a busca pelo realismo computacional se tornou um foco para além do próprio entretenimento. Modelagens físicas, algoritmos computacionais, redes neurais e deep learning. Cada um destes métodos possui um avanço significativo no desempenho de renderização gráfica e principalmente no realismo atingido. No entanto, em uma era de

intenso uso de hardware, como GPUs avançadas, a relação entre desempenho extraído e consumo energético torna-se uma questão fundamental a se avaliar. Neste artigo, fizemos uma análise a respeito do desempenho de renderização gráfica da GPU NVIDIA RTX 5060 aplicada ao jogo Cyberpunk 2077, desenvolvido pela CD PROJEKT RED, usando o DLSS 4.5 em comparação à sua eficiência energética.

2. Fundamentação Teórica

2.1. Deep Learning Super Sampling (DLSS)

Segundo [Watson 2020], o Deep Learning Super Sampling (DLSS), é um método que, para obter a Super-Resolução (SR), utiliza de imagens de baixa resolução, junto de vetores de movimento que carregam contexto como deslocamento, como fonte aplicada em uma Rede Neural Convolucional (CNN) treinada para gerar uma versão de alta resolução a partir do quadro inicial, o tipo de rede neural, é classificado pelo autor como “autoencoder convolucional”, e processa quadro a quadro. Atualmente a NVIDIA emprega diversos recursos para além do SR, como Frame Generation, DLAA, Ray Tracing, Path Tracing e Vision Transformer.

2.2. Convolutional Neural Network (CNN)

[Watson 2020], elenca que a CNN, uma técnica baseada em Deep Learning, exige menos pré-processamento do que técnicas tradicionais de SR, onde são treinadas especificamente para detecção de “características-chaves” da imagem fonte, podendo, inclusive, serem utilizadas imagens sequenciais à fonte para auxiliar a CNN na identificação. As etapas para o treinamento da CNN são descritas por [Watson 2020] como avaliadas por algoritmos de função de perda (loss functions), que, em busca de obter um resultado mais aproximado da imagem de referência (ground-truth), analisam atributos da imagem original e comparam com a gerada.

2.3. Frame Interpolation

Embora chamada popularmente de “Frame Generation”, essa tecnologia é exatamente o mesmo princípio do “Frame Interpolation”, tratam-se de técnicas para criação de frames inexistentes com base em suas referências. Segundo [Liu et al. 2019], existem diferentes métodos de aplicação de Frame Interpolation, tais como “estimativa de correspondência entre quadros consecutivos por meio de ‘stereo matching’ ou previsão de fluxo óptico”, CNN através de quadros intermediários, “combinação de estimativa de movimento e síntese de quadros em etapa única de convolução”, uso duplo de modelos distintos de CNN para, primeiro “prever o fluxo óptico bidirecional entre as imagens de entrada” e em segundo passo “para sintetizar imagens interpoladas com base no fluxo previsto”. Todos eles métodos para criação de frames até então inexistentes com base em suas referências (tradução livre).

2.4. Deep Learning Anti-Aliasing (DLAA)

[Beregovyi and Butkiewicz 2025], apontam que o DLAA utiliza a mesma tecnologia do DLSS, no entanto com um objetivo diferente, desta forma, a busca fundamental do DLAA é a remoção do serrilhado (aliasing), desta forma, a utilização da CNN é feita de forma a operar diretamente na resolução nativa, buscando corrigir a imagem e não ampliar a

mesma, (tradução livre). Além disso, os autores elencam outras técnicas comuns de AA (Anti-Aliasing), como a Fast Approximate Anti-Aliasing (FAA), Temporal Anti-Aliasing (TAA) e o Super Sampling Anti Aliasing (SSAA).

Os autores apontam que o TAA “atua acumulando informações de várias quadros” e então “utiliza vetores de movimento para alinhar quadros anteriores ao atual” oferecendo “boa qualidade com impacto mínimo no desempenho” embora “pode introduzir artefatos de ‘ghosting’ e desfoque de detalhes finos” quando em movimento rápido. Já em comparação, o DLAA “oferece AA aprimorado com melhor preservação de detalhes finos em comparação ao TAA”, mas em contrapartida, possui “um custo de desempenho mais elevado do que o do TAA” (tradução livre).

2.5. Ray Reconstruction

[Kazmierczyk et al. 2025], apontam que embora o NVIDIA Ray Reconstruction seja um software sem informações, públicas, é possível que o algoritmo aplique algo similar a “remoção de ruído e superamostragem em conjunto, prevendo kernels de filtro de remoção de ruído multiescala e kernels de filtro de aumento de resolução a partir de uma única arquitetura de rede”, assim, ao juntar remoção de ruído e aumento de resolução em uma única CNN, faz-se possível “compartilhar parâmetros aprendidos no espaço de características para prever com eficiência kernels de filtro de remoção de ruído e kernels de filtro de aumento de resolução”. Aliado a isso, ao focar em menor quantidade de pixels (baixa renderização), o modelo atua diretamente na “remoção de ruídos neurais” para a reconstrução dos pixels (tradução livre).

2.6. Ray Tracing

[Whitted 1980] aponta diversos algoritmos para aplicação de shaders, inicialmente elencando a lei do cosseno de Lambert, base para algoritmos mais simples para superfície visível, onde “a intensidade da luz é refletida proporcionalmente ao produto escalar da normal da superfície e da direção da fonte de luz, simulando um difusor perfeito e simulando uma aproximação razoável de superfícies foscas” Outro modelo citado pelo autor, é o de Bui-Tuong Phong, que “pressupõe que cada fonte de luz esteja localizada em um ponto infinitamente distante dos objetos na cena”, no entanto, tal modelo desconsidera que um objeto dentro da cena pode ser um fonte de luz, e consequentemente também não considera reflexo de iluminação proveniente de um reflexo de objetos já em cena (reflexo de reflexo).

Segundo o autor, o método de Blinn e Newell resolve o problema de Phong ao “modelar o ambiente de um objeto e o mapear em uma esfera de raios infinitos” (tradução livre). Além das fontes de luz, os modelos de iluminação também procuram desenvolver sombras, e para isso propõem alguns métodos específicos. [Whitted 1980] lista duas técnicas que alguns métodos podem utilizar para modelagem de efeitos de sombra, a primeira, é a aplicação do “algoritmo de superfície visível duas vezes”, sendo essa para modelar a fonte de luz e como interage com os objetos em cena, e a outra para a visão do observador e como a luz incide em sua percepção, a segunda é a utilização de “cálculos simplificados para determinar se o ponto é visível para a fonte de luz”, (tradução livre).

Para o efeito de transparência, é feita através de sobrescrita parcial através de pintura em ordem reversa, permitindo que “porções da imagem pintadas anteriormente

apareçam” [Whitted 1980] (tradução livre), posteriormente aprimorada por Kay, a técnica passou a produzir efeitos de refração.

2.7. Path Tracing

Inicialmente propostas por [Kajiya 1986], as equações que compõem o path tracing são modeladas de tal forma que “[a] equação afirma que a intensidade de transporte da luz de um ponto da superfície para outro é simplesmente a soma da luz emitida e da intensidade total da luz que é espalhada em direção a ‘x’ a partir de todos os outros pontos da superfície.”, (tradução livre). Desta forma, o path tracing foca na iluminação global da cena, e não de um objeto específico. Atualmente, existem vários métodos de resolução para o path tracing, [Yan et al. 2025], descrevem o funcionamento da Neural Rendering, como um método que “utiliza imagens de entrada correspondentes a certas condições da cena (ponto de vista, iluminação, layout, etc.). Em seguida, ela constrói uma representação ‘neural’ da cena a partir dessa entrada e a ‘renderiza’ sob novas propriedades da cena para sintetizar novas imagens.”, (tradução livre).

2.8. Vision Transformer

Ao analisar a aplicação de Transformer em visão (computacional) de baixo nível, [Khan et al. 2022], separam sua análise em três principais técnicas, a primeira “Transformers for Image Processing Tasks” a técnica proposta por Chen et al. como “um modelo pré-treinado baseado na arquitetura Transformer, denominado Image Processing Transformer (IPT).”, em sua análise o autor continua “[ele] é capaz de realizar diversas tarefas de restauração de imagens, como super-resolution, denoising, and deraining” (tradução livre). Ao descrever o IPT, [Khan et al. 2022], elenca a arquitetura do modelo como “múltiplas cabeças e múltiplas caudas para lidar com diferentes tarefas separadamente, além de um corpo Transformer codificador-decodificador compartilhado.” (tradução livre).

A segunda técnica citada por [Khan et al. 2022], “Transformers for Super-Resolution”, baseia-se no uso de CNN e “depende da escolha do objetivo de otimização”, o autor explica que mesmo que os resultados “baseados em função de perda calculada pixel a pixel” elas ainda possuem algumas desvantagens, como “dificuldade em recuperar detalhes finos de textura e frequentemente produzem imagens excessivamente suavizadas e menos agradáveis do ponto de vista perceptivo”, o autor ainda cita que a depender das “características profundas” das CNNs pré-treinadas, é possível com que “além da perda calculada pixel a pixel, empregam perda adversarial e perda perceptiva” (tradução livre).

A terceira técnica evidenciada por [Khan et al. 2022], “Colorization and Stylization Transformer”, como sendo “um modelo probabilístico baseado em um mecanismo de atenção condicional”, o autor aponta que “[ele] divide a tarefa de colorização de imagens em três subproblemas e propõe resolver cada tarefa sequencialmente por meio de uma rede Transformer diferente.”, este modelo é aplicado para problemas de colorização baseada em uma entrada de escala de cinza, assim, “[trata-se] de uma tarefa do tipo ‘um-para-muitos’, uma vez que, para uma determinada entrada em grayscale, existem inúmeras possibilidades no espaço de saída colorido”, onde a principal dificuldade é “gerar múltiplas amostras de saída coloridas” (tradução livre).

3. Resultados

3.1. Arquitetura de Análise Baseada em Múltiplos Agentes

Para realizar a etapa de análise dos dados foi utilizada uma arquitetura com LLM's baseada em múltiplos agentes. Todos os arquivos de prompt e resultados, bem como os dados utilizados obtidos a partir do NVIDIA FrameView ao executar o benchmark padrão do jogo, estão disponíveis em <https://github.com/pedroernesto64/Arquivos-Trabalho-DLSS5/>. Como apresentado em [Pérez et al. 2025], o uso de um modelo desses permite ultrapassar as limitações inerentes aos “pipelines” com somente um agente, tais como o tamanho restrito da janela de contexto e as dificuldades em processar dados estruturados de forma direta, e também fornece uma maior confiabilidade nos resultados. O objetivo principal da arquitetura é dividir o problema de analisar os dados em etapas que possam ser realizadas pelas LLM's de forma eficiente e com baixo risco. Ao especializar diferentes agentes para cada etapa, são evitados os problemas enfrentados quando LLM's são responsáveis por muitos passos de execução e erros cometidos se tornam difíceis de serem identificados.




Figura 1. Arquitetura da Pipeline de Agentes

Para a construção da arquitetura, primeiro foi fornecida uma breve descrição e contextualização do trabalho, bem como a planilha com os dados dos testes realizados, para um Gerador de Alto Nível, que formulou 6 perguntas gerais e exploratórias relacionando as diferentes variáveis apresentadas nos dados:

- Como o aumento progressivo do multiplicador de Multi Frame Generation (Sem FG, 2x, 3x e 4x) afeta a eficiência energética da GPU RTX 5060 em termos de FPS por Watt nos diferentes perfis de Qualidade DLSS?
- Qual é o impacto adicional em consumo elétrico e elevação térmica provocado pela ativação do Ray Reconstruction em comparação aos cenários em que apenas o Ray Tracing convencional está ativo?
- De que maneira a alternância entre os modos DLSS de maior qualidade (como DLAA) e de maior desempenho (como Desempenho Ultra) altera a distribuição de consumo elétrico e os percentuais de utilização entre a RTX 5060 e a CPU i5-12400F?
- Como a variação na taxa de consumo energético e na temperatura da GPU afeta a estabilidade da frequência de clock do núcleo da GPU e da memória?
- Qual combinação específica de parâmetros minimiza a potência total combinada do sistema mantendo uma taxa de quadros fluida ?
- Em que medida a alteração da resolução interna de renderização proporcionada pelo DLSS impacta a temperatura de operação ('CPU Temp') e a potência consumida ('CPU Package Power') da CPU Intel Core i5-12400F durante o jogo?

Adicionalmente, foi incluída uma pergunta elaborada pelo próprio grupo a fim de investigar a causa da discrepância de parte dos dados do número de frames por segundo obtido de forma direta a partir do jogo e a partir do FrameView:

- Em alguns momentos há uma discrepância grande entre o FPS medido diretamente pelo jogo e o FPS medido pelo Frameview. Essa discrepância tem relação com outras métricas, ou é mero acaso?

Com a primeira etapa da análise concluída, iniciou-se intervenção do segundo agente, Gerador de Baixo Nível, que irá utilizar as hipóteses de alto nível para definir concretamente quais variáveis e como elas devem ser utilizadas para as análises. Como resultado, temos uma instrução estatística concreta para cada questionamento abstrato realizado. Utilizando a primeira pergunta como exemplificação, tem-se que ela questiona o efeito do aumento do Multi Frame Generation na eficiência energética da GPU para diferentes perfis de qualidade DLSS, porém ainda não instrui como esse efeito pode ser medido.

Com a ação do segundo agente, essa lacuna é preenchida ao especificar que deve ser calculada a média do número de frames ($\text{Avg FPS (FrameView)}$), associada ao consumo elétrico da GPU ($\text{GPU NV Power (Watts) (API)}$) e a eficiência energética derivativa ($\text{GPU FPS per Watt (Avg FPS / GPU NV Power)}$) agrupando os dados por multiplicador de Multi Frame Generation (Não, 2x, 3x, 4x). Com as instruções definidas, o Agente de Execução e Consulta em Python será responsável por elaborar e executar o código Python para interagir com a tabela dos dados, extraindo os resultados numéricos necessários para responder a cada questão.

Uma vez calculados estes resultados exatos a partir do código, o agente converte as saídas matemáticas em afirmações no formato de texto natural, preparando a informação de forma legível para a etapa seguinte. Nesta etapa, é feita separadamente uma análise humana do código e, em seguida, uma execução independente. Esse passo permite um maior rigor na validação dos resultados, uma vez que a conclusão não fica dependente apenas da interpretação do modelo com LLM's, mas utiliza também a execução e análise humana.

Por fim, as respostas em formato de texto geradas na etapa anterior são repassadas para o último agente do sistema, responsável pela síntese e validação dos resultados. Ele consolida essas informações técnicas dispersas em uma única conclusão clara, coesa e de utilidade prática. Para verificar a confiabilidade da saída, o módulo utiliza um mecanismo de reflexão iterativa. Ele compara o texto que acabou de redigir com os dados reais extraídos pelo script Python. Esse ciclo de validação serve para identificar e cortar qualquer 'alucinação' (informações inventadas pelo modelo), exageros ou contradições, assegurando que a análise entregue ao utilizador seja estritamente fiel aos dados originais.

Como resultado da última etapa do sistema multi-agente, tivemos as respostas em forma de texto para as perguntas definidas no início do processo. Com elas, foi possível realizar uma verificação humana final desses resultados, para avaliar se realmente refletem as características dos dados da tabela e dos dados obtidos da execução do código independente da arquitetura, e chegar a conclusões do impacto do uso do DLSS 4.5.

3.2. Análise de Desempenho, Consumo e Eficiência Energética

A partir da síntese gerada pela arquitetura multi-agente, validada por posterior revisão humana em confronto com os dados empíricos, extraíram-se conclusões definitivas sobre o impacto do DLSS e da geração de quadros no sistema de testes. Relativamente à primeira

pergunta, notou-se que a tecnologia de interpolação impulsionou o número de quadros gerados por Watt de 0,6025 FPS/Watt (sem geração de quadros) para 1,6600 FPS/Watt. Este resultado representa um ganho de fluidez na ordem dos 175,5%, exigindo um aumento de consumo na GPU de apenas 4,8%. Demonstra-se assim que a fluidez do jogo foi maximizada sem inflacionar consideravelmente o envelope elétrico da placa gráfica.

O segundo resultado observado também trata do consumo energético, porém, no contexto do uso do Ray Reconstruction em adição ao Ray Tracing e abordando inclusive a variação térmica do sistema. Observou-se que o uso dessa tecnologia implementada por IA eleva o consumo médio da GPU em 5,00W (de 117,54W para 122,54W) e a temperatura média em 0,78°C (de 61,18°C para 61,96°C), apresentando uma correlação linear quase perfeita entre potência e temperatura, com uma medição do coeficiente de correlação linear de Pearson (r) de 0,9840. Apesar de ter um impacto pequeno nessas medições, o uso do Ray Reconstruction traz um prejuízo adicional ao promover uma redução média de 19,72 FPS no desempenho geral. Desta forma, o benefício desse recurso pode variar de acordo com a prioridade da taxa de quadros máxima.

Também houve interesse na análise de avaliar qual o modo do DLSS levaria a um menor consumo elétrico, considerando a energia consumida pela CPU e pela GPU, variando entre os níveis de qualidade e de desempenho, como o DLAA e o Desempenho Ultra. Pelos resultados, notou-se que a transição do DLSS DLAA para o modo Desempenho Ultra reduziu o uso da GPU de 97,5% para 83,4% e deslocou o gargalo para o i5-12400F, cuja utilização sobe de 32,0% para 70,0%. Consequentemente, a razão de potência GPU/CPU cai de 4,50 (115,40W GPU / 25,73W CPU) para 2,41 (104,67W GPU / 43,63W CPU).

Esse comportamento demonstra que uma maior prioridade para a velocidade dos quadros leva ao sobrecarregamento do processador, alterando a matriz energética do sistema. Além de avaliar os efeitos das variáveis separadamente, a análise também investigou qual configuração mantém uma boa fluidez do jogo enquanto demanda baixo consumo energético do sistema, procurando uma otimização dos parâmetros. Com o uso da arquitetura baseada em múltiplos agentes, concluiu-se que a combinação com DLSS DLAA, Frame Generation 4x sem Ray Reconstruction revelou-se a mais econômica. Essa configuração entrega 66,26 FPS exigindo apenas 121,12W de potência total (99,44W na GPU e 21,67W na CPU), tratando-se da solução ideal para operar o conjunto RTX 5060 e i5-12400F com máxima eficiência energética global (0,5470 FPS/Watt Total).

Ao se tratar da última das perguntas geradas pelo modelo, foi feito o questionamento do efeito da resolução interna da renderização na temperatura de operação da CPU e a potência consumida da CPU Intel Core i5-12400F. Concluiu-se pela análise que a diminuição da resolução base provocada pelos perfis mais agressivos de DLSS eleva progressivamente a temperatura e o consumo da CPU. O consumo da CPU escala de 25,73W (42,06°C) no DLAA até 43,63W (45,86°C) no Desempenho Ultra, representando um aumento de 69,54% no consumo do processador. Esse incremento térmico e elétrico indica que a economia de potência na GPU em DLSS agressivo é parcialmente anulada pela maior exigência sobre a CPU.

Em relação ao questionamento do grupo que foi adicionado ao processamento da arquitetura de análise, eram abordadas as discrepâncias nas medições do FPS medidas

diretamente pelo jogo e as medidas pelo Frameview. A partir da análise dos 15 registros de maior variação, notou-se que todos os outliers ocorriam exclusivamente sob FG 4x (66,7%) e FG 3x (33,3%) e o caso com maior diferença foi registrado nas configurações DLSS Balanceado e FG 4x, sem Ray Reconstruction, no qual o FrameView marcou 125,09 FPS enquanto a engine do jogo reportou apenas 30,96 FPS (razão de 4,0403). Esse resultado indica que o contador interno do jogo desconsidera os quadros sintetizados por IA, que são contabilizados integralmente pelo medidor externo do FrameView.

A análise da discrepância entre os registros de FPS do jogo (Avg FPS) e o FrameView revela que as variações são diretamente determinadas pelo multiplicador de Frame Generation. Sem FG, a diferença média é irrelevante - 0,44 FPS, razão 0,9874 - porém escala para 23,48 FPS em FG 2x (razão 1,5410), 48,07 FPS em FG 3x (razão 2,0669) e 65,60 FPS em FG 4x (razão 2,57720), atingindo picos de razão próximo a 3,98. Isso demonstra empiricamente que o jogo reporta apenas os quadros nativos renderizados pela engine, enquanto o FrameView quantifica a taxa real incluindo os quadros sintetizados por IA. Em síntese, a aplicação da arquitetura multi-agente provou ser uma metodologia altamente eficaz para a extração e validação de insights complexos.

Os resultados demonstram que, embora tecnologias gerativas como o Frame Generation ofereçam ganhos expressivos de eficiência para a placa gráfica, o uso de perfis agressivos de upscaling altera profundamente a matriz energética do equipamento, deslocando o gargalo computacional e o custo térmico para o processador central. Conclui-se, portanto, que a otimização de hardware contemporâneo exige uma análise holística do conjunto — um equilíbrio que o sistema de inteligência artificial desenvolvido neste trabalho conseguiu mapear com precisão matemática, unindo a capacidade de raciocínio lógico dos modelos de linguagem ao rigor técnico exigido pela engenharia.

Em síntese, os resultados evidenciam que a adoção de tecnologias de inteligência artificial gráfica, como o Frame Generation, é capaz de maximizar expressivamente a eficiência energética da placa de vídeo, garantindo alta fluidez visual com impacto mínimo no consumo elétrico. No entanto, constatou-se que o uso de perfis agressivos de upscaling altera substancialmente a matriz energética do equipamento: ao aliviar a carga gráfica, o gargalo computacional e a sobrecarga térmica são imediatamente transferidos para o processador central (CPU).

Adicionalmente, verificou-se que recursos de iluminação avançada, como o Ray Reconstruction, impõem penalidades de desempenho que exigem avaliação criteriosa de custo-benefício. A análise das métricas revela que a configuração ideal foge dos extremos de desempenho para encontrar o seu ponto de equilíbrio. Empiricamente, a combinação da resolução nativa (DLAA) com a máxima geração de quadros (FG 4x) provou ser a solução mais vantajosa, entregando a melhor relação de eficiência global entre a fluidez visual e o custo termelétrico do sistema.

h.1: Avaliar o impacto do Multi Frame Generation (Off, 2x, 3x, 4x) na eficiência energética (FPS/Watt) da RTX 5060 sob diferentes perfis DLSS. s1.1: Média de FPS, Power e FPS/Watt agrupada por MultiFrameGeneration (Off, 2, 3, 4). s1.2: Média de FPS, Power e FPS/Watt por perfil de DLSS (sob 4x FG). s1.3: Variação percentual ($\Delta\%$) da eficiência (FPS/Watt) nas transições 2x $\rightarrow$ 3x e 3x $\rightarrow$ 4x FG
h.2: Mensurar o incremento no consumo elétrico e na elevação térmica da GPU decorrente da ativação do Ray Reconstruction versus Ray Tracing convencional. s2.1: Média de Power, Temp e FPS agrupada por RayReconstruction (Sim/Não). s2.2: Coeficiente de correlação de Pearson (r) entre temperatura e potência da GPU. s2.3: Estatísticas descritivas (Min, Máx, Desvio Padrão) da temperatura da GPU com RayReconstruction ativado.
h.3: Analisar a distribuição do consumo elétrico e o percentual de uso entre GPU (RTX 5060) e CPU (i5-12400F) nos extremos dos modos DLSS (DLAA vs. Desempenho Ultra). s3.1: Razão de potência (GPU/CPU), uso de GPU e CPU nos extremos de DLSS (DLAA vs DesempenhoUltra). s3.2: Potência média individual de CPU e GPU por perfil de DLSS.
h.4: Investigar a estabilidade dos clocks do núcleo e da memória da GPU em função da variação de potência e temperatura. s4.1: Frequência média de clock (núcleo e memória) agrupada por faixas de potência da GPU (<115W, 115W - 125W, >125W). s4.2: Coeficiente de correlação de Pearson (r) entre temperatura e clock do núcleo da GPU.
h.5: Identificar a combinação ótima (DLSS, FG e Ray Reconstruction) que minimiza o consumo total do sistema (GPU + CPU) mantendo $\text{FPS} \geq 60$. s5.1: Filtragem de registros com FPS60 para identificar a menor potência combinada (GPU+CPU). s5.2: Extração dos parâmetros ótimos (DLSS, FG, RayReconstruction, FPS, potências e eficiência global).
h.6: Determinar o impacto térmico e de consumo da CPU (i5-12400F) associado à variação da resolução de renderização via DLSS. s6.1: Média de temperatura, potência e uso da CPU agrupada por perfil de DLSS. s6.2: Variação percentual ($\Delta\%$) na potência da CPU do modo nativo (DLAA) para o modo de maior reconstrução (DesempenhoUltra).
h.7: Caracterizar a distribuição, as médias e as correlações globais das discrepâncias de FPS entre a engine do jogo e o FrameView. s7.1: Estatísticas descritivas globais (média, mediana, desvio padrão, min, máx) de FPS_Delta e FPS_Ratio. s7.2: Agrupamento por MultiFrameGeneration e DLSS para média e amplitude de FPS_Delta e FPS_Ratio. s7.3: Matriz de correlação de Pearson (r) global entre FPS_Delta e as demais métricas de desempenho e uso.
h.8: Avaliar a frequência das discrepâncias de FPS sob o uso de Multi Frame Generation (MFG) e sua correlação com parâmetros de qualidade gráfica e carga de hardware. s8.1: Frequência absoluta e percentual de discrepâncias significativas ($\text{FPS_Delta} > 5$) com MFG Ligado vs Desligado. s8.2: Cruzamento da magnitude/frequência de discrepância com perfis de DLSS e RayReconstruction (com MFG Ligado). s8.3: Análise da discrepância sob MFG Ligado em função da carga de trabalho (GPU/CPU util%).

Figura 2. Tabela de Hipóteses com suas respectivas métricas para testá-las.

4. Conclusão

Este trabalho apresentou uma avaliação abrangente do desempenho, do custo térmico e da eficiência energética da arquitetura de renderização neural guiada por DLSS e Multi Frame Generation aplicada à GPU RTX 5060 no jogo Cyberpunk 2077. Com o auxílio de uma arquitetura baseada em múltiplos agentes, utilizando Grandes Modelos de Linguagem (LLM), foi possível formular, processar e validar hipóteses complexas com rigor técnico e empírico, mitigando vieses e automatizando o tratamento de um grande volume de dados de hardware.

Os resultados obtidos demonstram que tecnologias de interpolação baseadas em inteligência artificial, como o Frame Generation (4 $\times$), são altamente eficazes para maximizar a fluidez visual — registrando ganhos expressivos na taxa de quadros por Watt sem inflacionar de maneira drástica o envelope elétrico da placa gráfica. No entanto, constatou-se que a adoção de perfis agressivos de upscaling e de recursos avançados de iluminação, a exemplo do Ray Reconstruction, altera profundamente a matriz energética do sistema. Ao aliviar a carga computacional primária da GPU, observa-se o deslocamento do gargalo e da sobrecarga térmica para o processador central (CPU), evidenciando que a busca por eficiência exige uma análise holística do hardware.

Por fim, a investigação indicou que a configuração ideal afasta-se dos extremos de desempenho. A combinação entre a resolução nativa via DLAA e a máxima geração de quadros (FG 4 $\times$) consolidou-se como o ponto de equilíbrio mais vantajoso, entregando excelente fluidez visual com o menor custo termelétrico global. Como trabalhos futuros,

sugere-se a expansão desta metodologia multiagente para diferentes arquiteturas de hardware e títulos de grande porte, visando a consolidação de diretrizes automatizadas para a otimização energética em jogos eletrônicos.

Referências

- Beregovyi, K. and Butkiewicz, T. (2025). Visual integrity in the age of ai: An evaluation of dlss and dlaa in geospatial visualization. In *2025 IEEE Visualization and Visual Analytics (VIS)*, pages 291–295, Vienna, Austria.
- Kajiya, J. T. (1986). The rendering equation. *SIGGRAPH Comput. Graph.*, 20(4):143–150.
- Kazmierczyk, P., Kim, S., Uss, W., Kalinski, W., Galaj, T., Maciejewski, M., and Harihara, R. (2025). Joint denoising and upscaling via multi-branch and multi-scale feature network. *Proc. ACM Comput. Graph. Interact. Tech.*, 8(1).
- Khan, S., Naseer, M., Hayat, M., Zamir, S. W., Khan, F. S., and Shah, M. (2022). Transformers in vision: A survey. *ACM Comput. Surv.*, 54(10s).
- Liu, Y.-L., Liu, Y.-T., Lin, Y.-Y., and Chuang, Y.-Y. (2019). Deep video frame interpolation using cyclic frame generation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 8794–8802.
- Pérez, A. S., Papotti, P., Boukhary, A., Lozano, L. C., and Elwood, A. (2025). An llm-based approach for insight generation in data analysis. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 562–582. Association for Computational Linguistics.
- Watson, A. (2020). Deep learning techniques for super-resolution in video games.
- Whitted, T. (1980). An improved illumination model for shaded display. *Commun. ACM*, 23(6):343–349.
- Yan, R., Guo, H., Huang, L., Xiao, N., Li, S., Wang, Y., Lv, Y., and Chen, G. (2025). A survey on deep learning for monte carlo path tracing. *ACM Comput. Surv.*, 58(4).